# Day20 flume

hadoop flume

- 大数据数据采集
- flume
  - spooling Source hdfs sink
  - avro source logger sink
- flume节点故障和消息瓶颈问题
  - 节点故障问题
  - 消息瓶颈问题
  - 多个节点串行化操作

# 大数据数据采集

数据来源形式	数据来源格式	文件传输
网络爬虫	html文档	flume、kafka
日志数据	log文件, 日志流	flume、kafka
业务数据	关系型数据库	sqoop
传感数据	数据流	kafka

## flume

Flume是Cloudera提供的一个高可用的,高可靠的,分布式的海量日志采集、聚合和传输的系统,Flume支持在日志系统中定制各类数据发送方,用于收集数据;同时,Flume提供对数据进行简单处理,并写到各种数据接受方(可定制)的能力。

对于flume的学习和其他的不太一样,我们需要依赖官网上的文档进行开发,官网用户手册http://flume.apache.org/FlumeUserGuide.html 和官网开发手册

 $http: \!\!/\!\!flume.apache.org/FlumeDeveloperGuide.html$ 

flume数据采集的数据来源:

- 1. log文件
- 2. 网路端口数据
- 3. 消息队列数据

flume数据发送来源

- 1. hdfs
- 2. hive
- 3. hbase
- 4. 网络端口
- 5. 消息队列

flume-ng将采集的过程交给用户开发agent来直接指定, agent中有三个组件Source、Channel(相当于缓冲区)、sink(目的是从channel中取数据)

• Event: 一个数据单元,带有一个可选的消息头

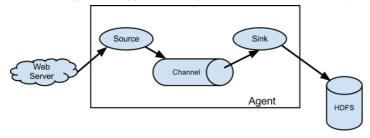
• Flow: Event从源点到达目的点的迁移的抽象

- Client:操作位于源点处的Event,将其发送到Flume Agent
- Agent: 一个独立的Flume进程,包含组件Source、Channel、Sink
- Source: 用来消费传递到该组件的Event
- Channel: 中转Event的一个临时存储, 保存有Source组件传递过来的Event
- Sink: 从Channel中读取并移除Event,将Event传递到Flow Pipeline中的下一个Agent(如果有的话)

Flume 的核心是把数据从数据源收集过来,再送到目的地。为了保证输送一定成功,在送到目的地之前,会先缓存数据,待数据真正到达目的地后,删除自己缓存的数据。

Flume 传输的数据的基本单位是 Event,如果是文本文件,通常是一行记录,这也是事务的基本单位。 Event 从 Source,流向 Channel,再到 Sink,本身为一个 byte 数组,并可携带 headers 信息。 Event 代表着一个数据流的最小完整单元,从外部数据源来,向外部的目的地去。

Flume 运行的核心是 Agent。它是一个完整的数据收集工具,含有三个核心组件,分别是 source、channel、sink。通过这些组件,Event 可以从一个地方流向另一个地方,如下图所示。



- source 可以接收外部源发送过来的数据。不同的 source,可以接受不同的数据格式。比如有目录池(spooling directory)数据源,可以监控指定文件夹中的新文件变化,如果目录中有文件产生,就会立刻读取其内容。
- channel 是一个存储地,接收 source 的输出,直到有 sink 消费掉 channel 中的数据。channel 中的数据直到进入到下一个channel中或者进入终端才会被删除。当 sink 写入失败后,可以自动重启,不会造成数据丢失,因此很可靠。
- sink 会消费 channel 中的数据,然后送给外部源或者其他 source。如数据可以写入到 HDFS 或者 HBase 中。

```
al.sources = r1
al.sinks = s1
al.channels = c1

al.sources.rl.type = netcat
al.sources.rl.bind = localhost
al.sources.rl.port = 44444

al.sinks.sl.type = logger

al.channels.cl.type= memory
al.channels.cl.capacity = 1000
al.channels.cl.transactionCapacity = 100

al.sources.rl.channels = c1
al.sinks.sl.channel = c1
```

netcat:source的一种类型, 网络抓取

bind: 资源来源

flume的整个数据采集过程,数据是被封装到Event里面进行传输的

采集日志log文件,把结果存放到hdfs上

#### log生成的方式

- 1. 滚动生成
  - o 按时间滚动
  - o 按文件大小滚动

当有新日志文件产生的时候,把刚写完的日志系统拷贝搭配spoolingdirectory

### spooling Source hdfs sink

source: Spooling Directory Source

channel: memory sink: hdfs sink

```
al.sources = rl
al.sinks=sl
al.channels=cl

al.sources.rl.type = spooldir
al.sources.rl.spoolDir = /root/tmp
al.sources.rl.fileHeader = true

al.sinks.sl.type = hdfs
al.sinks.sl.hdfs.path = hdfs://master:9000/flumelog/%Y%m%d
al.sinks.sl.hdfs.fileSuffix = .log
al.sinks.sl.hdfs.rollInterval = 0
al.sinks.sl.hdfs.rollSize = 0
al.sinks.sl.hdfs.rollSize = 0
al.sinks.sl.hdfs.rollCount = 100
al.sinks.sl.hdfs.fileType = DataStream
al.sinks.sl.hdfs.writeFormat = Text
al.sinks.sl.hdfs.useLocalTimeStamp = true

al.channels.cl.type= memory
al.channels.cl.tansactionCapacity = 100
al.sources.rl.channels = cl
al.sinks.sl.channel = cl
```

```
执行操作 flume-ng agent -c conf -f flume_nc_to_hdfs.conf --name a1 - Dflume.root.logger=INFO.console
```

## avro source logger sink

avro文件作为数据采集的对象, logger作为消费者消费的格式 现在我们模拟出avro文件的格式发送数据到agent中, 下面的java程序就是模拟代码

```
package top.xiesen.bd14;

import java.nio.charset.Charset;
import java.util.Date;
import java.util.HashMap;
import java.util.Map;

import org.apache.flume.Event;
import org.apache.flume.EventDeliveryException;
import org.apache.flume.api.RpcClient;
import org.apache.flume.api.RpcClientFactory;
import org.apache.flume.event.EventBuilder;
```

```
public class FlumeClient {
private RpcClient flumeClient;
private String hostname;
private int port;
public FlumeClient() {
  super();
public FlumeClient(String hostname, int port) {
  this.hostname = hostname;
  this.port = port;
  this.flumeClient = RpcClientFactory.getDefaultInstance(hostname, port);
public void sendEvent(String msg) {
 Map<String, String> headers = new HashMap<>();
  headers.put("timestamp", String.valueOf(new Date().getTime()));
  Event event = EventBuilder.withBody(msg, Charset.forName("UTF-8"), headers);
  try {
  flumeClient.append(event);
  } catch (EventDeliveryException e) {
  e.printStackTrace();
   // 单条发送失败重新连接
   flumeClient = null;
   flumeClient = RpcClientFactory.getDefaultInstance(hostname, port);
public void cleanUp() {
  flumeClient.close();
public static void main(String[] args) {
  FlumeClient flumeClient = new FlumeClient("master", 8888);
  String bMsg = "fromjava-msg";
for(int i = 0; i < 100; i++) {</pre>
   flumeClient.sendEvent(bMsg + i);
  flumeClient.cleanUp();
```

#### 下面是avro---> logger的配置文件

```
al.sources = r1
al.sinks=s1
al.channels=c1

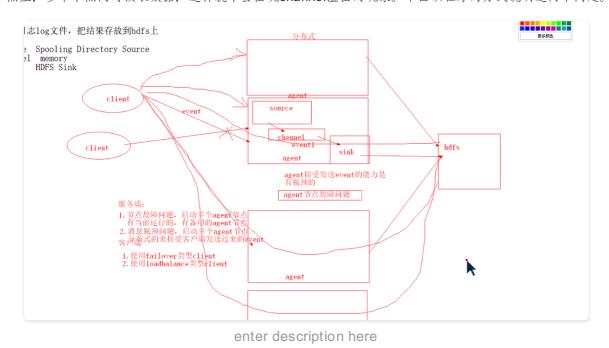
al.sources.rl.type = avro
al.sources.rl.bind = master
al.sources.rl.port = 8888

al.channels.cl.type= memory
al.channels.cl.capacity = 1000
al.channels.cl.transactionCapacity = 100
al.sinks.sl.type = logger
```

al.sources.rl.channels = cl

# flume节点故障和消息瓶颈问题

flume 节点在运行的时候可能会挂掉,导致我们的数据无法正常的进行采集,在生活中我们是不愿意出现这种现象的。我们采用分布式的方式来解决节点故障问题,同时打开多个节点,如果出现节点挂掉现象,其他的节点随时待命接收数据,处理日志信息。flume在运行的时候也会出现channel中出现了很多的event,但是sink消费的比较缓慢,慢慢的会出现channel溢出的现象,这也不是我们想要看到的现象,对于这个问题我们也采用分布式进行解决。我们可以将event发送到多个节点上,多个节点同时读取数据,这样就不会出现channel溢出的现象。下面以程序的方式说明这两个问题。



• 简要解决方案

#### 服务端:

- 1. 节点故障问题, 启动多个agent节点, 由当前运行的, 有备用的agent节点
- 2. 消息瓶颈问题, 启动多个agent节点, 分布式的来接受客户端发送的event

#### 客户端

- 1. 使用failover类型client
- 2. 使用loadbalance类型client

### 节点故障问题

节点故障问题,服务端采用多个节点同时运行的方式进行,有当前节点运行,其他节点备用;客户端采用failover类型

• 客户端

创建fileover client.conf文件,这里我们配置了连个节点,master是主节点,slaver1是备用节点

```
client.type = default_failover
hosts = h1 h2
hosts.h1 = master:8888
hosts.h2 = slaver1:8888
```

max-attempts = 2

```
package top.xiesen.bd14;
import java.io.File;
import java.io.FileInputStream;
import java.io.InputStream;
import java.nio.charset.Charset;
import java.util.Properties;
import org.apache.flume.Event;
import org.apache.flume.EventDeliveryException;
import org.apache.flume.api.RpcClient;
import org.apache.flume.api.RpcClientFactory;
import org.apache.flume.event.EventBuilder;
public class FileoverClient {
private Properties properties;
private RpcClient failoverClient;
public FileoverClient() throws Exception {
  this.properties = new Properties();
  InputStream inputStream = new FileInputStream(new File("src/main/resources/fileover
 properties.load(inputStream);
  this.failoverClient = RpcClientFactory.getInstance(properties);
public void sendEvent(String msg) {
  Event event = EventBuilder.withBody(msg, Charset.forName("UTF-8"));
   failoverClient.append(event);
  } catch (EventDeliveryException e) {
   e.printStackTrace();
public void close() {
  failoverClient.close();
public static void main(String[] args) throws Exception {
  FileoverClient fileoverClient = new FileoverClient();
  for (int i = 0; i < 100; i++) {</pre>
   fileoverClient.sendEvent(msg+i);
   Thread.sleep(1000);
  fileoverClient.close();
```

• 服务端 服务端运行多个flume程序就可以了,记住启动备用节点

### 消息瓶颈问题

消息瓶颈问题,服务端启动多个agent节点,分布式的来接受客户端发送的event。客户端使用loadbalance类型

• 配置文件

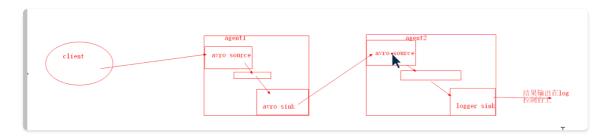
```
client.type = default_loadbalance
hosts = h1 h2
hosts.h1 = master:8888
hosts.h2 = slaver1:8888
host-selector = random
```

• 发送程序, 我们这里采用随机发送

```
package top.xiesen.bd14;
import java.io.File;
import java.io.FileInputStream;
import java.io.IOException;
import java.io.InputStream;
import java.nio.charset.Charset;
import java.util.Properties;
import org.apache.flume.Event;
import org.apache.flume.EventDeliveryException;
import org.apache.flume.api.RpcClient;
import org.apache.flume.api.RpcClientFactory;
import org.apache.flume.event.EventBuilder;
public class LoadBalanceClient {
private RpcClient lbClient;
private Properties properties;
public LoadBalanceClient() throws Exception {
  this.properties = new Properties();
  InputStream inputStream = new FileInputStream(new File("src/main/resources/load bala
  properties.load(inputStream);
  this.lbClient = RpcClientFactory.getInstance(properties);
public void sendEvent(String msg) {
  Event event = EventBuilder.withBody(msg, Charset.forName("UTF-8"));
   lbClient.append(event);
  } catch (EventDeliveryException e) {
   e.printStackTrace();
public void close(){
public static void main(String[] args) throws Exception {
  LoadBalanceClient loadBalanceClient = new LoadBalanceClient();
  String msg = "lbmsg_";
for(int i = 0; i < 100; i++) {</pre>
   loadBalanceClient.sendEvent(msg + i);
  loadBalanceClient.close();
```

## 多个节点串行化操作

需求分析: 我们的需求是客户端以avro的方式将数据发送出去。节点一以avro的方式输出,然后将输出的avro文件发送给第二个节点,第二个节点将数据打印到控制台。当然,你也可以将数据保存到hdfs上或者hive等等



#### 1. 书写第一个节点的服务端程序

```
al.sources = rl
al.sinks=sl
al.channels=cl

al.sources.rl.type = avro
al.sources.rl.bind = master
al.sources.rl.port = 9999

al.channels.cl.type= memory
al.channels.cl.capacity = 1000
al.channels.cl.transactionCapacity = 100

al.sinks.sl.type = avro
al.sinks.sl.hostname = slaverl
al.sinks.sl.port = 9998

al.sources.rl.channels = cl
al.sinks.sl.channel = cl
```

#### 2. 书写第二个服务端程序

```
al.sources = r1
al.sinks=s1
al.channels=c1

al.sources.rl.type = avro
al.sources.rl.bind = slaver1
al.sources.rl.port = 9998

al.channels.cl.type= memory
al.channels.cl.capacity = 1000
al.channels.cl.transactionCapacity = 100

al.sinks.sl.type = logger

al.sources.rl.channels = c1
al.sinks.sl.channel = c1
```

#### 3. 使用代码模拟产生avro文件,将文件发送到第一个节点上

```
package top.xiesen.bd14;
import java.nio.charset.Charset;
import java.util.Date;
import java.util.HashMap;
```

```
import java.util.Map;
import org.apache.flume.Event;
import org.apache.flume.EventDeliveryException;
import org.apache.flume.api.RpcClient;
import org.apache.flume.api.RpcClientFactory;
import org.apache.flume.event.EventBuilder;
public class FlumeClient {
private RpcClient flumeClient;
private String hostname;
private int port;
public FlumeClient() {
  super();
public FlumeClient(String hostname, int port) {
  this.hostname = hostname;
  this.port = port;
  this.flumeClient = RpcClientFactory.getDefaultInstance(hostname, port);
public void sendEvent(String msg) {
 Map<String, String> headers = new HashMap<>();
  headers.put("timestamp", String.valueOf(new Date().getTime()));
  Event event = EventBuilder.withBody(msg, Charset.forName("UTF-8"), headers);
  try {
  flumeClient.append(event);
  } catch (EventDeliveryException e) {
   flumeClient.close();
   flumeClient = null;
   flumeClient = RpcClientFactory.getDefaultInstance(hostname, port);
public void cleanUp() {
  flumeClient.close();
public static void main(String[] args) {
  FlumeClient flumeClient = new FlumeClient("master",9999);
  String bMsg = "fromjava-msg";
for(int i = 0; i < 100; i++) {</pre>
  flumeClient.cleanUp();
```

4. 如果在第二个节点上的控制台上看到我们发送的数据,说明我们是成功的