Day14_Hive

Hadoop Day14 Hive 优化 窗口函数 日志分析

```
Day14 Hive
    Hive窗口函数
        简介
        概念
        数据准备
        聚合函数+over
        partition by子句
        order by子句
        window子句
    窗口函数中的序列函数
        NTILE
        LAG和LEAD函数
    课堂练习
        数据准备
        ntile函数的应用
        rank(), dense_rank(), row_number()函数的应用
        数学函数+over函数
    日志分析
    Hive优化
        Group by 优化
        order by 优化
        sql语句优化
```

join 优化

Hive窗口函数

简介

本文主要介绍hive中的窗口函数.hive中的窗口函数和sql中的窗口函数相类似,都是用来做一些数据分析类的工作,一般用于olap分析

概念

我们都知道在sql中有一类函数叫做聚合函数,例如sum()、avg()、max()等等,这类函数可以将多行数据按照规则聚集为一行,一般来讲聚集后的行数是要少于聚集前的行数的.但是有时我们想要既显示聚集前的数据,又要显示聚集后的数据,这时我们便引入了窗口函数.

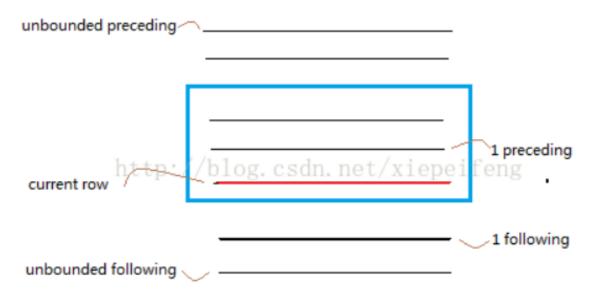
在深入研究Over字句之前,一定要注意:在SQL处理中,窗口函数都是最后一步执行,而且仅位于Order by字句之前.

首先,我们要知道什么是窗口子句:

需要指定一个窗口的边界, 语法是这样的:

ROWS between CURRENT ROW | UNBOUNDED PRECEDING | [num] PRECEDING AND UNBOUNDED FOLLOWING | [num] FOLLOWING | CURRENT ROW 或

RANGE between [num] PRECEDING AND [num]FOLLOWING 如下图:



ROWS是物理窗口,从行数上控制窗口的尺寸的;

RANGE是逻辑窗口,从列值上控制窗口的尺寸。这个比较难理解,但说白了就简单了,具体解释如下面例子.

结合order by子句使用,如果在order by子句后面没有指定窗口子句,则默认为:range between unbounded preceding and current row

数据准备

我们准备一张order表,字段分别为name,orderdate,cost.数据内容如下:

```
jack,2015-01-01,10
tony,2015-01-02,15
jack,2015-02-03,23
tony,2015-01-04,29
jack,2015-04-06,42
tony,2015-01-07,50
jack,2015-01-08,55
mart,2015-04-08,62
mart,2015-04-09,68
neil,2015-05-10,12
mart,2015-04-11,75
neil,2015-06-12,80
mart,2015-04-13,94
```

在hive中建立一张表t window,将数据插入进去.

聚合函数+over

假如说我们想要查询在2015年4月份购买过的顾客及总人数,我们便可以使用窗口函数去去实现

```
select name,count(*) over()
from t_window
where substring(orderdate,1,7) = '2015-04'
```

得到的结果如下:

```
name count_window_0
mart 5
mart 5
mart 5
mart 5
jack 5
```

可见其实在2015年4月一共有5次购买记录,mart购买了4次,jack购买了1次.事实上,大多数情况下,我们是只看去重后的结果的.针对于这种情况,我们有两种实现方式

• 第一种: distinct

```
select distinct name,count(*) over()
from t_window
where substring(orderdate,1,7) = '2015-04'
```

第二种:group by

```
select name,count(*) over()
from t_window
where substring(orderdate,1,7) = '2015-04'
group by name
```

执行后的结果如下:

```
name count_window_0
mart 2
jack 2
```

partition by子句

Over子句之后第一个提到的就是Partition By.Partition By子句也可以称为**查询分区子句**,非常类似于Group By,都是将数据按照边界值分组,而**Over之前的函数在每一个分组之内进行,如果超出了分组,则函数会重新计算**.

我们想要去看顾客的购买明细及月购买总额,可以执行如下的sql

```
select name,orderdate,cost,sum(cost)
over(partition by month(orderdate))
from t_window
```

执行结果如下:

```
orderdate cost
                       sum_window_0
name
     2015-01-01 10
jack
                           205
jack
     2015-01-08 55
tony
     2015-01-07 50
                           205
jack 2015-01-05 46
     2015-01-04 29
tony
tony
     2015-02-03 23
                           23
jack
mart
                           341
     2015-04-06 42
jack
                           341
     2015-04-11 75
                           341
mart
mart 2015-04-09 68
                           341
mart
                           341
neil
                           12
neil
      2015-06-12 80
```

可以看出数据已经按照月进行汇总了.

order by子句

上述的场景,假如我们想要将cost按照月进行累加.这时我们引入order by子句.

order by子句会让输入的数据强制排序(文章前面提到过,窗口函数是SQL语句最后执行的函数,因此可以把SQL结果集想象成输入数据)。Order By子句对于诸如Row_Number(),Lead(),LAG()等函数是必须的,因为如果数据无序,这些函数的结果就没有任何意义。因此如果有了Order By子句,则Count(),Min()等计算出来的结果就没有任何意义。

我们在上面的代码中加入order by

```
select name,orderdate,cost,sum(cost)
over(partition by month(orderdate) order by orderdate )
from t_window
```

得到的结果如下:(order by默认情况下聚合从起始行当当前行的数据)

name	orderdate	cost	sum_window_0
jack	2015-01-01	10	10
tony	2015-01-02	15	25
tony	2015-01-04	29	54
jack	2015-01-05	46	100
tony	2015-01-07	50	150
jack	2015-01-08	55	205
jack	2015-02-03	23	23
jack	2015-04-06	42	42
mart	2015-04-08	62	104
mart	2015-04-09	68	172
mart	2015-04-11	75	247
mart	2015-04-13	94	341
neil	2015-05-10	12	12
neil	2015-06-12	80	80

window子句

我们在上面已经通过使用partition by子句将数据进行了分组的处理.如果我们想要**更细粒度的**划分,我们就要引入window子句了.

我们首先要理解两个概念:

- 如果只使用partition by子句,未指定order by的话,我们的聚合是分组内的聚合.
- 使用了order by子句,未使用window子句的情况下,默认从起点到当前行.

当同一个select查询中存在多个窗口函数时,他们相互之间是没有影响的.每个窗口函数应用自己的规则.

window子句:

PRECEDING:往前FOLLOWING:往后

• CURRENT ROW: 当前行

• UNBOUNDED:起点, UNBOUNDED PRECEDING 表示从前面的起点,

UNBOUNDED FOLLOWING: 表示到后面的终点

我们按照name进行分区,按照购物时间进行排序,做cost的累加. 如下我们结合使用window子句进行查询

```
select name,orderdate,cost,
--所有行相加
sum(cost) over() as sample1,
--按name分组, 组内数据相加
sum(cost) over(partition by name) as sample2,
--按name分组, 组内数据累加
sum(cost) over(partition by name order by orderdate) as sample3,
--和sample3一样,由起点到当前行的聚合
sum(cost) over(partition by name order by orderdate rows between UN
BOUNDED PRECEDING and current row ) as sample4 ,
--当前行和前面一行做聚合
sum(cost) over(partition by name order by orderdate rows between 1
PRECEDING and current row) as sample5,
--当前行和前边一行及后面一行
sum(cost) over(partition by name order by orderdate rows between 1
PRECEDING AND 1 FOLLOWING ) as sample6,
--当前行及后面所有行
sum(cost) over(partition by name order by orderdate rows between current row and UNBOUNDED FOLLOWING ) as sample7
from t_window;
```

得到查询结果如下:

name	orderdate	cost	samnle1	samnle?	sample3	samnle4	samnle5
	sample7	030	Samples	Samplez	Samples	Sampter	Samp tes
jack	2015-01-01	10	661	176	10	10	10
56	176						
jack	2015-01-05	46	661	176	56	56	56
111	166						
jack	2015-01-08	55	661	176	111	111	101
124	120						
jack	2015-02-03	23	661	176	134	134	78
120	65						
jack	2015-04-06	42	661	176	176	176	65
65	42						
mart	2015-04-08	62	661	299	62	62	62
130	299						
mart	2015-04-09	68	661	299	130	130	130
205	237						
mart	2015-04-11	75	661	299	205	205	143
237	169						
mart	2015-04-13	94	661	299	299	299	169
169	94						
neil	2015-05-10	12	661	92	12	12	12
92	92						
neil	2015-06-12	80	661	92	92	92	92
92	80						
tony	2015-01-02	15	661	94	15	15	15
44	94	20	661	0.4	4.4	4.4	4.4
tony	2015-01-04	29	661	94	44	44	44
94	79	F.0	C C 1	0.4	0.4	0.4	70
tony	2015-01-07	50	661	94	94	94	79
79	50						

窗口函数中的序列函数

主要序列函数是不支持window子句的.

hive中常用的序列函数有下面几个:

NTILE

NTILE(n),用于将分组数据按照顺序切分成n片,返回当前切片值

NTILE不支持ROWS BETWEEN , 比如 NTILE(2) OVER(PARTITION BY cookieid ORDER BY createtime ROWS BETWEEN 3 PRECEDING AND CURRENT ROW)

- 如果切片不均匀,默认增加第一个切片的分布
- 这个函数用什么应用场景呢?假如我们想要每位顾客购买金额前1/3的交易记录,我们便可以使用这个函数.

得到的数据如下:

name	orderdate	cost	sample1	sample2	sample3	sample4
jack	2015-01-01	10	3	1	1	1
jack	2015-02-03	23	3	1	1	1
jack	2015-04-06	42	2	2	2	2
jack	2015-01-05	46	2	2	2	2
jack	2015-01-08	55	2	3	2	3
mart	2015-04-08	62	2	1	2	1
mart	2015-04-09	68	1	2	3	1
mart	2015-04-11	75	1	3	3	2
mart	2015-04-13	94	1	1	3	3
neil	2015-05-10	12	1	2	1	1
neil	2015-06-12	80	1	1	3	2
tony	2015-01-02	15	3	2	1	1
tony	2015-01-04	29	3	3	1	2
tony	2015-01-07	50	2	1	2	3

如上述数据,我们去sample4 = 1的那部分数据就是我们要的结果

```
row_number、rank、dense_rank
```

这三个窗口函数的使用场景非常多

- row_number()从1开始,按照顺序,生成分组内记录的序列,row_number()的值不会存在重复,当排序的值相同时,按照表中记录的顺序进行排列
- RANK() 生成数据项在分组中的排名,排名相等会在名次中留下空位
- DENSE_RANK() 生成数据项在分组中的排名,排名相等会在名次中不会留下空位

注意: rank和dense rank的区别在于排名相等时会不会留下空位.**

举例如下:

```
SELECT

cookieid,

createtime,

pv,

RANK() OVER(PARTITION BY cookieid ORDER BY pv desc) AS rn1,

DENSE_RANK() OVER(PARTITION BY cookieid ORDER BY pv desc) AS rn2,

ROW_NUMBER() OVER(PARTITION BY cookieid ORDER BY pv DESC) AS rn3

FROM lxw1234

WHERE cookieid = 'cookie1';
```

得到的数据如下:

cookieid day	pv	rn1	rn2	rn3
cookie1 2015-04-12	7	1	1	1
cookie1 2015-04-11	5	2	2	2
cookie1 2015-04-15	4	3	3	3
cookie1 2015-04-16	4	3	3	4
cookie1 2015-04-13	3	5	4	5
cookie1 2015-04-14	2	6	5	6
cookiel 2015-04-10	1	7	6	7

rn1: 15号和16号并列第3, 13号排第5 rn2: 15号和16号并列第3, 13号排第4

rn3: 如果相等,则按记录值排序,生成唯一的次序,如果所有记录值都相等,或许会随机

排吧。

LAG和LEAD函数

这两个函数为常用的窗口函数,可以返回上下数据行的数据.

以我们的订单表为例,假如我们想要查看顾客上次的购买时间可以这样去查询

```
select name,orderdate,cost,
lag(orderdate,1,'1900-01-01') over(partition by name order by order
date ) as time1,
lag(orderdate,2) over (partition by name order by orderdate) as tim
e2
from t_window;
```

查询后的数据为:

```
orderdate cost
                       time1 time2
name
      2015-01-01 10 1900-01-01 NULL
jack
      2015-01-05 46 2015-01-01 NULL
jack
jack
      2015-02-03 23 2015-01-08 2015-01-05
jack
     2015-04-06 42 2015-02-03 2015-01-08
jack
      2015-04-08 62 1900-01-01 NULL
mart
      2015-04-09 68 2015-04-08 <u>NULL</u>
mart
mart 2015-04-11 75 2015-04-09 2015-04-08
      2015-04-13 94 2015-04-11 2015-04-09
mart
neil 2015-05-10 12 1900-01-01 NULL
neil
      2015-06-12 80 2015-05-10 NULL
     2015-01-02 15 1900-01-01 NULL
tony
      2015-01-04 29 2015-01-02 NULL
tony
      2015-01-07 50 2015-01-04 2015-01-02
tony
```

time1取的为按照name进行分组,分组内升序排列,取上一行数据的值.

time2取的为按照name进行分组,分组内升序排列,取上面2行的数据的值,注意当lag函数为设置行数值时,默认为1行.未设定取不到时的默认值时,取null值.

lead函数与lag函数方向相反,取向下的数据.

first_value和last_value

- first_value取分组内排序后,截止到当前行,第一个值
- last_value取分组内排序后,截止到当前行,最后一个值

```
select name,orderdate,cost,
first_value(orderdate) over(partition by name order by orderdate) a
s time1,
last_value(orderdate) over(partition by name order by orderdate) as
time2
from t_window
```

查询结果如下:

```
orderdate cost
name
                       time1
                                 time2
jack
      2015-01-01 10 2015-01-01 2015-01-01
      2015-01-05 46 2015-01-01 2015-01-05
jack
jack
                                2015-01-08
     2015-02-03 23 2015-01-01 2015-02-03
jack
jack
     2015-04-08 62 2015-04-08 2015-04-08
mart
     2015-04-09 68 2015-04-08 2015-04-09
mart
     2015-04-11 75 2015-04-08 2015-04-11
mart
     2015-04-13 94 2015-04-08 2015-04-13
mart
neil
     2015-06-12 80 2015-05-10 2015-06-12
neil
tony
tony
     2015-01-04 29 2015-01-02 2015-01-04
      2015-01-07 50 2015-01-02 2015-01-07
tony
```

课堂练习

数据准备

```
create table order_items(
    order_item_id int,
    order_id int,
    product_id int,
    quantity tinyint,
    subtotal float,
    product_price float
)

row format delimited
fields terminated by '|'

load data inpath '/orderdata/order_items'
overwrite into table order_items
```

ntile函数的应用

```
create table ntile_order_item
stored as orc
as
select order_item_id,
    order_id,
    product_id,
    quantity,
    subtotal,
    product_price,
    ntile(2) over(order by product_price) splitno
from order_items

select splitno,
    avg(quantity)
from ntile_order_item
group by splitno
```

rank(), dense_rank(), row_number()函数的 应用

计算每个产品,每个订单的销量排名

```
create table rank_order_item
stored as orc
select order_item_id,
       product_id,
       quantity,
       rank() over(partition by product_id order by quantity desc),
       dense_rank() over(partition by product_id order by quantity
desc),
       row_number() over(partition by product_id order by quantity
desc)
from order_items
create table month_finish(
    date_month string,
    dep_name string,
    finish_amount string,
    task_amount string
fields terminated by '\t'
lines terminated by '\n'
stored as textfile;
load data local inpath '/opt/Software/Test/monthfinish.txt'
overwrite into table month_finish
```

数学函数+over函数

每个部门按照时间计算每个月的年累计完成销量

```
select date_month,
    dep_name,
    finish_amount,
    task_amount,
    -- 按照排序向上累计计算finish_amount值
    -- 等同于
    -- sum(finish_amount) over(partition by dep_name order by t
o_date(date_month) rows between unbounded preceding and current ro
w)
    sum(finish_amount) over(partition by dep_name order by to_da
te(date_month)),
    -- 计算部门一年总的完成量
    sum(finish_amount) over(partition by dep_name),
    -- 计算部门三个月的完成量
    sum(finish_amount) over(partition by dep_name order by to_da
te(date_month) rows between 2 preceding and current row),
    -- 计算部门当前往前两个月往后一个月的完成量
    sum(finish_amount) over(partition by dep_name order by to_da
te(date_month) rows between 2 preceding and 1 following),
    -- 计算部门累计完成量,往下累计
    sum(finish_amount) over(partition by dep_name order by to_da
te(date_month) rows between current row and unbounded following)
from month_finish
```

统计每个部门的年任务累计完成率

日志分析

原来我们将分析日志,是直接在SQuirrel工具上执行的,没有考虑到sql的固化操作,等等。下面以日志分析为例子,阐述一下sql固化的问题

1. 编写hql

dateday是一个变量名,将日期给抽取出来了,提高代码的复用率

```
use db14;
CREATE external TABLE if not exists apache_log (
  host STRING,
  identity STRING,
  username STRING,
  time STRING,
  request STRING,
  status STRING,
  size STRING,
  referer STRING,
  partitioned by (date_day string)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.RegexSerDe'
WITH SERDEPROPERTIES (
  "input.regex" = "([^ ]*) ([^ ]*) ([^ ]*) (-|\\[[^\\]]*\\]) ([^
\"]*|\"[^\"]*\") (-|[0-9]*) (-|[0-9]*)(?: ([^ \"]*|\"[^\"]*\") ([^
\"]*|\"[^\"]*\"))?"
  ,"output.format.string"="%1$s %2$s %3$s %4$s %5$s %6$s %7$s %8$s
%9$s"
STORED AS TEXTFILE;
alter table apache_log drop partition(date_day='${dateday}');
alter table apache_log add partition(date_day='${dateday}') locatio
n '/apachlog/${dateday}';
set hive.support.concurrency=true;
set hive.exec.dynamic.partition.mode=nonstrict;
set hive.txn.manager=org.apache.hadoop.hive.ql.lockmgr.DbTxnManage
set hive.compactor.initiator.on=true;
set hive.compactor.worker.threads=1;
create table if not exists day_pv_uv(
    date_day int
    ,pv int
    ,uv int
clustered by(date_day) into 2 buckets
stored as orc
tblproperties("transactional"="true");
delete from day_pv_uv where date_day = '${dateday}';
insert into day_pv_uv
select ${dateday}
    ,count(1) pv
```

```
,count(distinct host) uv
from apache_log
where date_day = '${dateday}';
```

2. 将hql上传到装hive的机器上

3. 执行 hive -f aa.hql -hivevar dateday=20171027

Hive优化

Group by 优化

Group By 很容易导致数据倾斜问题,因为实际业务中,通常是数据集中在某些点上,这也符合常见的2/8 原则,这样会造成对数据分组后,某一些分组上数据量非常大,而其他的分组上数据量很小,而在mapreduce 程序中,同一个分组的数据会分配到同一个reduce 操作上去,导致某一些reduce 压力很大,其他的reduce 压力很小,这就是数据倾斜,整个job 执行时间取决于那个执行最慢的那个reduce。解决这个问题的方法是配置一个参数:set hive.groupby.skewindata=true。当选项设定为 true,生成的查询计划会有两个 MR Job。第一个 MR Job 中, Map的输出结果会随机分布到 Reduce 中,每个 Reduce 做部分聚合操作,并输出结果,这样处理的结果是相同的Group By Key 有可能被分发到不同的 Reduce 中,从而达到负载均衡的目的;第二个 MR Job再根据预处理的数据结果按照 Group By Key 分布到 Reduce 中(这个过程可以保证相同的GroupBy Key 被分布到同一个Reduce 中),最后完成最终的聚合操作。

order by 优化

因为order by 只能是在一个reduce 进程中进行的,所以如果对一个大数据集进行 order by,会导致一个reduce 进程中处理的数据相当大,造成查询执行超级缓慢。在 要有进行order by 全局排序的需求时,用以下几个措施优化:

- 1. 在最终结果上进行order by , 不要在中间的大数据集上进行排序。如果最终结果较少 , 可以
 - 在一个reduce 上进行排序时,那么就在最后的结果集上进行order by。
- 2. 如果需求是取排序后前N 条数据,那么可以使用distribute by 和sort by 在各个reduce 上进行排

序后取前N条,然后再对各个reduce 的结果集合并后在一个reduce 中全局排序,再取前N条,因为参与

全局排序的Order By 的数据量最多有reduce 个数*N, 所以速度很快。

```
select a.leads_id,a.user_name from
(
    select leads_id,user_name from dealer_leads
    distribute by length(user_name) sort by length(user_name) desc
limit 10
) a order by length(a.user_name) desc limit 10;
```

sql语句优化

- 1. 尽量在select后面不要用*,需要哪些字段,使用字段名称来获取
- 2. 尽量不要使用distinct,用group by的特性来对数据进行排重

- 3. 使用exists和not exists代替in和not in
- 4. 有些时候or和可以使用union方式代替

join 优化

• 优先过滤后再join,最大限度地减少参与Join 的数据量。

```
select *
from employee a
inner join department b
on a.belong_dep_code=b.dep_code
where a.gender='女' and b.dep_address like '%北京%'

select *
from (
    select * from employee where gender='女'
)a
inner join (
    select * from department where dep_address like '%北京%'
) b
on a.belong_dep_code=b.dep_code
```

• 表 join 大表原则

应该遵守小表join 大表原则,原因是Join 操作的reduce 阶段,位于join 左边的表内容会被加载进内存,将条目少的表放在左边,可以有效减少发生内存溢出的几率。join 中执行顺序是从做到右生成Job,应该保证连续查询中的表的大小从左到右是依次增加的。

• join on 条件相同的放入一个job

hive 中,当多个表进行join 时,如果join on 的条件相同,那么他们会合并为一个 MapReduce Job,所以利用这个特性,可以将相同的join on 的放入一个job 来节省执行时间。

```
select pt.page_id,count(t.url) PV
from rpt_page_type pt
join
(
    select url_page_id,url from trackinfo where ds='2016-10-11'
) t on pt.page_id=t.url_page_id
join
(
    select page_id from rpt_page_kpi_new where ds='2016-10-11'
) r on t.url_page_id=r.page_id
group by pt.page_id;
```